Robustez y reversibilidad de estrategias y algoritmos de perturbación proactiva frente a contramedidas adversarias en el entrenamiento no autorizado de modelos discriminativos: una revisión sistemática de la literatura

Rodrigo Calli[1*], Franco Aguilar[1], Glender Vargas[1], DR Soria Quijaite[1]

[1]Escuela Profesional de Ingeniería de Sistemas, Universidad Peruana Unión, Lima, Perú.

*Corresponding author(s). E-mail(s): rodrigo.calli@upeu.edu.pe;

Resumen

Las perturbaciones proactivas, conocidas como ejemplos no aprendibles o ataques de disponibilidad, modifican datos visuales antes de publicarlos para que un tercero no pueda entrenar con ellos un modelo discriminativo útil. Su valor como mecanismo de protección depende de que el efecto persista cuando el adversario aplica contramedidas. Esta revisión sistemática, conducida según Kitchenham y Charters y reportada según PRISMA 2020, examina qué protecciones se han propuesto, qué contramedidas se han evaluado y bajo qué supuestos del adversario, cuánta recuperación del rendimiento logran esas contramedidas y con qué referencias experimentales se mide. Se consultaron Scopus, Web of Science, IEEE Xplore y SpringerLink, además de una colección previa del equipo; de 770 registros se incluyeron 64 estudios primarios (2020–2026). Cuarenta y un estudios entraron en la síntesis y 23 aportaron 3070 comparaciones con comparabilidad sustentada, todas en imagen 2D salvo un estudio imagen-texto. La mediana entre estudios de la recuperación del adversario fue de 26,4 puntos porcentuales (pp) de exactitud (rango intercuartílico 8,0–34,3) y la brecha mediana remanente respecto del entrenamiento limpio fue de 37,0 pp; en promedio, el 12,6 % de las comparaciones de cada estudio quedó a 5 pp o menos del régimen limpio. La purificación generativa mostró las mayores recuperaciones (mediana 66,8 pp; tres estudios) y los aumentos de datos convencionales las menores (4,7 pp; ocho estudios). Los estudios que proponen una contramedida informaron recuperaciones

mayores que los que proponen una protección (34,3 frente a 15,7 pp), lo que indica una dependencia del resultado respecto de quién diseña la evaluación. Ningún estudio definió un umbral operativo de protección suficiente, 43 de 64 no informaron repeticiones y 23 de los 55 estudios con condición de contramedida no incluyeron el control limpio con esa misma contramedida. La evidencia disponible no sostiene que las protecciones actuales sean robustas frente a un adversario con acceso a modelos generativos de purificación, y la comparación entre estudios está limitada por referencias experimentales heterogéneas.

Palabras clave: ejemplos no aprendibles, ataques de disponibilidad, protección de datos, contramedidas adversarias, purificación, revisión sistemática

1. Introducción

El entrenamiento de modelos de aprendizaje profundo con datos recolectados sin autorización plantea un problema de control sobre el uso de imágenes personales o protegidas. Una línea de investigación propone que el titular modifique sus datos antes de publicarlos mediante perturbaciones de baja magnitud que no alteran su uso humano pero impiden que un modelo discriminativo entrenado con ellos generalice. Una formulación de referencia, los ejemplos no aprendibles mediante ruido minimizador del error [1], fue seguida por variantes robustas al entrenamiento adversario [2, 3], perturbaciones sintéticas que no requieren modelo sustituto [4–6] y extensiones al aprendizaje contrastivo [7], a modelos imagen-texto [8] y a datos tridimensionales [9, 10]. En paralelo se desarrolló el camuflaje de imágenes faciales frente a modelos de reconocimiento entrenados sin autorización [11].

La utilidad de estas protecciones depende de un supuesto que no siempre se examina: que el efecto persista cuando quien entrena aplica contramedidas. Varios trabajos han mostrado que compresiones simples [12], purificación con modelos de difusión [13, 14] o autocodificadores variacionales [15] recuperan buena parte del rendimiento. A la vez, cada estudio emplea su propio conjunto de protecciones, contramedidas, presupuestos, arquitecturas y referencias de comparación, lo que impide saber si las discrepancias entre estudios reflejan diferencias reales de robustez o diferencias en la forma de evaluar.

Las revisiones disponibles describen el campo, pero no cuantifican la recuperación del adversario bajo un criterio explícito de comparabilidad. Una revisión de datos no aprendibles organiza métodos, métricas y aplicaciones [16]; una sistematización reciente relaciona la no aprendibilidad con el desaprendizaje de máquinas [17]; y una revisión de seguridad frente al envenenamiento del entrenamiento trata estas técnicas como un caso dentro del envenenamiento indiscriminado [18]. Ninguna aplica un protocolo sistemático con evaluación de calidad, ni separa las comparaciones interpretables de las que no lo son antes de agregar magnitudes.

Esta revisión responde cuatro preguntas (Tabla 3). Sus aportes son: (i) una caracterización de 64 estudios primarios según la estrategia de protección, la modalidad, las

contramedidas y el modelo de adversario; (ii) una síntesis cuantitativa de 3070 comparaciones entre la condición protegida y la condición con contramedida, restringida a pares con comparabilidad sustentada y agregada por estudio para evitar que los estudios con más celdas dominen el resultado; y (iii) un diagnóstico de las referencias experimentales que hoy limitan la comparación entre estudios, con recomendaciones verificables para su reporte.

El resto del artículo se organiza de la siguiente manera. La Sección 2 define los conceptos empleados y presenta las revisiones relacionadas. La Sección 3 describe el protocolo de revisión, que comprende las preguntas de investigación, la estrategia de búsqueda, los criterios de selección, la evaluación de la calidad y la extracción y síntesis de los datos. La Sección 4 presenta los resultados para cada pregunta de investigación y la Sección 5 los discute. La Sección 6 examina las amenazas a la validez y la Sección 7 resume las conclusiones y las líneas de trabajo futuro.

2. Antecedentes

2.1. Perturbación proactiva y contramedidas

En esta revisión, una *perturbación proactiva* es una modificación que el titular aplica a sus datos visuales antes de publicarlos, con el fin de degradar la utilidad de un modelo discriminativo entrenado o ajustado con ellos sin autorización. La literatura la denomina también ejemplo no aprendible, dato no explotable o ataque de disponibilidad. El concepto excluye dos fenómenos próximos: las perturbaciones que actúan solo durante la inferencia de un modelo ya entrenado y las protecciones dirigidas exclusivamente contra modelos generativos.

Una *contramedida* es cualquier procedimiento que el adversario aplica a los datos protegidos o a su propio entrenamiento para recuperar el rendimiento del modelo. Incluye las transformaciones y compresiones de la entrada, los aumentos de datos, el entrenamiento adversario, la purificación mediante modelos generativos, los cambios del paradigma de aprendizaje y la detección y descarte de las muestras protegidas. La *recuperación autorizada* es un caso distinto: un actor legítimo dispone de información o recursos del titular para restituir la aprendibilidad del dato.

2.2. Condiciones de comparación y medidas de recuperación

La evaluación de una contramedida requiere comparar el rendimiento de modelos entrenados bajo cuatro condiciones:

- con datos limpios bajo el régimen estándar;
- con datos protegidos sin la contramedida;
- con datos protegidos después de aplicar la contramedida;
- con datos limpios sometidos a la misma contramedida.

A partir de ellas se definen tres magnitudes, orientadas según la dirección de la métrica:

- la *recuperación*, diferencia entre el rendimiento con contramedida y el rendimiento protegido sin ella;

Tabla 1 Revisiones relacionadas y diferencias con la presente revisión

Revisión	Alcance	Diferencia con esta revisión
Li et al. (2025) [16]	Métodos de generación de datos no aprendibles, benchmarks, métricas, fundamentos teóricos y aplicaciones; compara enfoques por no aprendibilidad, imperceptibilidad, eficiencia y robustez	Revisión narrativa, sin protocolo sistemático ni evaluación de calidad; no cuantifica la recuperación del adversario
Zhang et al. (2026) [17]	Sistematización conjunta de no aprendibilidad y desaprendizaje de máquinas, con evaluación empírica propia y una garantía teórica sobre la desmemorización	Analiza la relación entre ambas defensas; no sintetiza la evidencia publicada sobre contramedidas
Cinà et al. (2022) [18]	Ataques y defensas de envenenamiento del entrenamiento en aprendizaje automático, con énfasis en visión por computadora	Trata la perturbación proactiva como un caso del envenenamiento indiscriminado; no aborda su uso como protección de datos

- la *brecha al entrenamiento limpio*, diferencia entre el rendimiento limpio y el obtenido con contramedida;
- la *brecha al control con contramedida*, diferencia respecto del entrenamiento limpio sometido a la misma contramedida.

Cuando la métrica es la exactitud en porcentaje, las tres se expresan en puntos porcentuales (pp).

Las magnitudes se interpretan en conjunto:

- Una recuperación alta con una brecha baja al entrenamiento limpio indica que la contramedida neutraliza la protección.
- Una brecha alta al entrenamiento limpio con una brecha baja al control indica que la pérdida remanente se debe a la propia contramedida y no a la protección.

2.3. Revisiones relacionadas

Tres trabajos de síntesis abordan el tema desde perspectivas distintas (Tabla 1). Li et al. [16] revisan los métodos de generación de datos no aprendibles, sus benchmarks, métricas y aplicaciones, y comparan los enfoques en términos de no aprendibilidad, imperceptibilidad, eficiencia y robustez. Zhang et al. [17] relacionan la no aprendibilidad con el desaprendizaje de máquinas y aportan una evaluación empírica propia. Cinà et al. [18] sistematizan los ataques y defensas de envenenamiento del entrenamiento, dentro de los cuales la perturbación proactiva aparece como un caso de envenenamiento indiscriminado. Los dos primeros trabajos son preimpresiones.

Ninguno de estos trabajos sigue un protocolo sistemático con criterios de calidad declarados ni cuantifica la recuperación del adversario frente a las protecciones. Esa síntesis cuantitativa, restringida a las comparaciones que pueden interpretarse, es el aporte de la presente revisión.

Tabla 2 Fases del proceso de revisión

Fase	Actividades
Planificación	Identificación de la necesidad de la revisión
	Formulación de las preguntas de investigación
	Elaboración del protocolo de revisión
Conducción	Búsqueda e identificación de estudios
	Selección de estudios primarios
	Evaluación de la calidad
	Extracción de datos
	Síntesis de datos
Reporte	Redacción y verificación del informe según PRISMA 2020

Tabla 3 Preguntas de investigación

ID	Pregunta de investigación
RQ1	¿Qué estrategias y algoritmos de perturbación proactiva se han propuesto para dificultar el entrenamiento no autorizado de modelos discriminativos con datos visuales, cómo se caracterizan y en qué tareas, conjuntos de datos y arquitecturas se han evaluado?
RQ2	¿Qué contramedidas se han evaluado frente a estas protecciones y bajo qué conocimientos, capacidades, acceso y recursos del adversario?
RQ3	¿Qué grado de protección persiste y qué recuperación del rendimiento logra el adversario tras aplicar las contramedidas evaluadas, en los distintos dominios y configuraciones experimentales?
RQ4	¿Qué referencias experimentales y métricas se utilizan para evaluar la robustez y la reversión adversaria, y en qué condiciones permiten comparar los resultados entre estudios y dominios?

3. Método

Esta revisión sigue el procedimiento de Kitchenham y Charters para revisiones sistemáticas en ingeniería de software [19] y se reporta conforme a la declaración PRISMA 2020 [20]. El procedimiento se organiza en tres fases (planificación, conducción y reporte) cuyas actividades se resumen en la Tabla 2. Antes de la búsqueda se elaboró un protocolo que fijó las preguntas de investigación, la estrategia de búsqueda, los criterios de selección, la evaluación de la calidad y el proceso de extracción y síntesis. [Indicar si el protocolo se registró y, en su caso, el repositorio, el identificador y las enmiendas.] Cada etapa se describe en los apartados siguientes.

3.1. Preguntas de investigación

El primer paso del protocolo fue formular las preguntas que orientan la revisión (Tabla 3). Su alcance se delimitó con el marco PICO:

- **Población:** datos visuales protegidos mediante perturbación proactiva.
- **Intervención:** contramedidas aplicadas a esos datos o a su entrenamiento.
- **Comparación:** entrenamiento con datos protegidos sin la contramedida, complementado con el entrenamiento limpio en condiciones comparables.
- **Resultado:** persistencia del efecto protector y recuperación del rendimiento.

Tabla 4 Fuentes de información

Base de datos	Campos de búsqueda	URL
Scopus	Título, resumen y palabras clave	https://www.scopus.com/
Web of Science	Tema (título, resumen y palabras clave)	https://www.webofscience.com/
IEEE Xplore	Todos los metadatos	https://ieeexplore.ieee.org/
SpringerLink	Búsqueda general de la plataforma	https://link.springer.com/

Cada pregunta cumple una función distinta:

- **RQ1** caracteriza las protecciones propuestas: cómo se generan, qué restricciones imponen, en qué modalidades y tareas se aplican y con qué conjuntos de datos y arquitecturas se evalúan. Esta caracterización es necesaria para interpretar las respuestas posteriores, porque la robustez de una protección depende de su mecanismo.
- **RQ2** identifica las contramedidas evaluadas y el modelo de adversario bajo el que se aplican. Una contramedida solo es relevante si sus supuestos sobre el conocimiento, el acceso y los recursos del adversario son verosímiles para el escenario de protección.
- **RQ3** cuantifica cuánto rendimiento recupera el adversario y cuánto efecto protector persiste. Es la pregunta central de la revisión.
- **RQ4** examina las referencias experimentales y las métricas con las que se mide la robustez, para determinar en qué condiciones los resultados de estudios distintos pueden compararse.

3.2. Estrategia de búsqueda

3.2.1. Fuentes de información

Se consultaron las cuatro bases de datos de la Tabla 4. Se eligieron por su cobertura de las revistas y actas de congresos de aprendizaje automático, visión por computadora y seguridad, y porque permiten búsquedas booleanas sobre los metadatos y la exportación de los registros. Como fuente complementaria se incorporó una colección de artículos conocidos por el equipo, consultada en la plataforma Undermind, que se reporta como otros métodos.

3.2.2. Cadena de búsqueda

La cadena combinó cinco conceptos mediante el operador OR (Tabla 5):

- la terminología propia de los datos no aprendibles;
- los ataques de disponibilidad, restringidos a contextos de aprendizaje con imágenes;
- las perturbaciones protectoras o proactivas;
- el envenenamiento indiscriminado y contrastivo;
- el camuflaje frente al reconocimiento facial.

Los ataques de disponibilidad se acotaron con términos de imagen y aprendizaje porque, sin esa restricción, el término recupera estudios de disponibilidad de servicios de

Tabla 5 Cadena de búsqueda

Concepto	Términos de búsqueda
Datos no aprendibles	("unlearnable example*" **OR** "unlearnable data" **OR** "unlearnable dataset*" **OR** "unlearnable sample*" **OR** "unlearnability" **OR** "error-minimizing noise" **OR** "unexploitable data" **OR** "robust unlearnable example*")
	OR
Ataques de disponibilidad	(("availability attack*" **OR** "availability poison*") **AND** (image* **OR** "training data" **OR** "deep learning" **OR** "machine learning"))
	OR
Perturbación protectora	("data-protecting perturbation*" **OR** "protective perturbation*" **OR** "proactive perturbation*")
	OR
Envenenamiento indiscriminado	("indiscriminate poison*" **OR** "contrastive poison*")
	OR
Camuflaje facial	(cloak* **AND** ("face recognition" **OR** "facial recognition"))

red. La cadena se adaptó a la sintaxis de cada base y se aplicaron los filtros de periodo (2020–2026) y de tipo documental (artículo de revista y ponencia de congreso). En Web of Science, por ejemplo, la consulta fue:

> TS=("unlearnable example*" OR "unlearnable data" OR "unlearnable dataset*" OR "unlearnable sample*" OR "unlearnability" OR "error-minimizing noise" OR "unexploitable data" OR "robust unlearnable example*" OR (("availability attack*" OR "availability poison*") AND (image* OR "training data" OR "deep learning" OR "machine learning")) OR "data-protecting perturbation*" OR "protective perturbation*" OR "proactive perturbation*" OR "indiscriminate poison*" OR "contrastive poison*" OR (cloak* AND ("face recognition" OR "facial recognition"))) AND PY=(2020-2026)

Las búsquedas se ejecutaron en octubre de 2026. Las cadenas completas de cada base se incluyen como material suplementario.

3.3. Criterios de selección

Los criterios de inclusión (Tabla 6) delimitan los estudios que pueden responder las preguntas de investigación. Los criterios de exclusión (Tabla 7) descartan los estudios que, aun tratando el tema, no cumplen otras condiciones necesarias. Dos de ellos separan fenómenos próximos que la búsqueda recupera con frecuencia: las protecciones que actúan solo en la inferencia (CE6) y las dirigidas contra modelos generativos (CE7). El uso de un modelo generativo como contramedida para purificar los datos no activa el criterio CE7.

La selección se realizó en dos etapas:

1. Tras eliminar los registros duplicados y las versiones de un mismo trabajo, dos revisores examinaron de forma independiente el título y el resumen de cada registro. Los registros sin una decisión clara pasaron a la lectura del texto completo.
2. En la etapa de elegibilidad, un revisor leyó el texto completo de cada estudio y el segundo revisor contrastó la decisión con la ficha de extracción y el acta de revisión del estudio.

Las discrepancias se resolvían por consenso; no se presentaron discrepancias en ninguna de las dos etapas.

Tabla 6 Criterios de inclusión

ID	Criterio
CI1	Estudio primario con evaluación empírica original, publicado como artículo completo en una revista o un congreso con revisión por pares.
CI2	Publicado entre 2020 y 2026.
CI3	Estudia datos visuales protegidos: imágenes, vídeos, pares imagen-texto con un componente visual pertinente o datos tridimensionales cuya tarea final sea discriminativa.
CI4	Evalúa perturbaciones proactivas destinadas a dificultar el entrenamiento o ajuste no autorizado de modelos discriminativos, o contramedidas frente a ellas.
CI5	Aporta evidencia pertinente para responder al menos una de las preguntas de investigación.
CI6	El texto completo está en inglés o español.

Tabla 7 Criterios de exclusión

ID	Criterio
CE1	No es una publicación primaria elegible: revisión, editorial, resumen sin artículo completo o preimpresión sin publicación arbitrada.
CE2	Publicado fuera del periodo establecido.
CE3	Texto completo en un idioma distinto del inglés o el español.
CE4	No estudia datos visuales pertinentes al objeto de la revisión.
CE5	Examina otro fenómeno, como el envenenamiento malicioso, las puertas traseras o el desaprendizaje de modelos, sin estudiar la protección proactiva.
CE6	La protección actúa exclusivamente durante la inferencia de un modelo fijo, sin una evaluación pertinente al entrenamiento o ajuste.
CE7	El objetivo es exclusivamente impedir el entrenamiento de modelos generativos.
CE8	No presenta una evaluación empírica pertinente a ninguna pregunta de investigación.

3.4. Evaluación de la calidad

La calidad de cada estudio incluido se valoró con las ocho preguntas de la Tabla 8. Las preguntas cubren la descripción técnica de la protección y de la contramedida, la identificación de datos y modelos, la separación entre desarrollo y prueba, la adecuación de los comparadores, la validez de las métricas, la incertidumbre, el reporte completo y la mesura de las conclusiones. La suma de las valoraciones, entre 0 y 8, no se utilizó para excluir estudios de la revisión, sino para decidir su participación en la síntesis.

3.5. Extracción de datos

Los datos se extrajeron con un formulario común para todos los estudios (Tabla 9). Cada valor se registró junto con su localización en la fuente (página, tabla o figura) y con su estado: informado, no informado, no evaluado por el estudio o no aplicable. La ausencia de una evaluación no se interpretó como un resultado nulo. Cuando un estudio presentaba varias configuraciones experimentales, se extrajeron por separado los resultados de cada una. [Declarar el uso de herramientas de inteligencia artificial en la extracción y el control humano aplicado, conforme a la política editorial de la revista.]

Tabla 8 Preguntas de evaluación de la calidad. Cada pregunta se valora como Sí (1), Parcial (0,5) o No (0); la información insuficiente y los casos no aplicables no puntúan

Aspecto evaluado	Pregunta
Descripción de la protección y la contramedida	¿La protección y, cuando corresponde, la contramedida están descritas con su procedimiento y configuración técnica?
Identificación de datos y modelos	¿Se identifican suficientemente los datos, la tarea, el modelo objetivo y el procedimiento de entrenamiento o ajuste?
Separación entre desarrollo y prueba	¿La evaluación evita la contaminación indebida entre desarrollo y prueba, de acuerdo con la tarea y el escenario declarado?
Adecuación de los comparadores	¿Los comparadores y las condiciones experimentales permiten interpretar el efecto evaluado bajo las capacidades declaradas del adversario?
Validez de las métricas	¿Las métricas están definidas y miden el resultado que el estudio afirma demostrar?
Incertidumbre de los resultados	¿Las repeticiones, las unidades evaluadas y las medidas de incertidumbre permiten valorar la estabilidad de los resultados?
Reporte completo	¿Se presentan los resultados de las evaluaciones anunciadas y se justifican las omisiones o selecciones realizadas?
Mesura de las conclusiones	¿Las conclusiones se limitan a lo demostrado y reconocen las limitaciones relevantes?

Tabla 9 Formulario de extracción de datos

Dimensión	Información extraída
Protección	Nombre, mecanismo de generación, espacio y granularidad de la perturbación, dependencia de un modelo sustituto
Restricciones	Norma y presupuesto de la perturbación, proporción de datos protegidos
Escenario de evaluación	Modalidad, tarea, conjuntos de datos, arquitecturas y procedimiento de entrenamiento
Contramedidas	Nombre, familia, procedimiento, parámetros, etapa de aplicación y adaptación a la protección
Adversario	Conocimiento de la protección, acceso a datos, etiquetas y modelos, recursos y restricciones
Condiciones comparadas	Entrenamiento limpio, protegido, protegido con contramedida, limpio con la misma contramedida y recuperación autorizada
Medición	Métricas, dirección, unidad, umbral operativo y resultados por condición
Incertidumbre	Repeticiones, semillas y medidas de dispersión
Recuperación autorizada	Actor, recursos y resultado de la restauración legítima
Costos y efectos	Costo de generación y calidad visual del dato protegido
Conclusiones	Conclusiones del estudio y limitaciones declaradas

3.6. Síntesis de los datos

Comparabilidad.

Cada par formado por la condición protegida y la condición con contramedida se clasificó según su comparabilidad:

- *sustentada*, cuando ambas condiciones comparten conjunto de datos, arquitectura, protocolo de entrenamiento y métrica, y la contramedida está especificada;
- *limitada*, cuando falta uno de esos elementos;
- *no determinable*, cuando la fuente no permite establecerla.

La ausencia de repeticiones o de medidas de dispersión se consideró una limitación de la precisión del resultado, no de su comparabilidad. Las magnitudes de la Sección 2.2 se calcularon solo para los pares con comparabilidad sustentada.

Niveles de síntesis.

Todos los estudios incluidos se caracterizaron para responder RQ1, RQ2 y RQ4. Participaron en la síntesis los estudios con una valoración de calidad igual o superior a 4,5 sobre 8 o con al menos una comparación sustentada. La síntesis cuantitativa de RQ3 se basó en los estudios con al menos una comparación sustentada.

Agrupación.

Las protecciones se agruparon según su estrategia de generación y las contramedidas según su familia. Cuando una condición combinaba contramedidas de varias familias, se asignó a la familia con mayor capacidad esperada de eliminar la perturbación, en este orden: purificación generativa, aumentos adversarios, entrenamiento adversario, transformación y compresión, aumentos de datos, proyección y sondas lineales, cambio de paradigma y detección.

Agregación.

Las comparaciones de un mismo estudio no son independientes y su número varía mucho entre estudios. Por ello, la agregación se realizó en dos pasos: primero se obtuvo la mediana dentro de cada estudio y después la mediana y el rango intercuartílico entre estudios. Como indicador de neutralización se calculó, para cada estudio, la proporción de comparaciones que quedan a 5 pp o menos del entrenamiento limpio, y se promedió entre estudios; los umbrales de 2 y 10 pp se informan como análisis de sensibilidad. No se realizó un metaanálisis, debido a la dependencia entre comparaciones, a la escasez de medidas de dispersión y a la heterogeneidad de las configuraciones.

4. Resultados

La aplicación del protocolo condujo a la selección de 64 estudios primarios (Fig. 1). En la fase de identificación se obtuvieron 739 registros de las bases de datos (Scopus, 157; Web of Science, 30; IEEE Xplore, 96; SpringerLink, 456) y 31 por otros métodos. Antes del cribado se eliminaron 128 registros: 101 duplicados entre bases, 19 duplicados entre otros métodos y las bases, y 8 versiones de un mismo trabajo.

Se cribaron por título y resumen 642 registros, de los cuales se excluyeron 556. Los motivos principales fueron no estudiar datos visuales pertinentes (248) y estar fuera del periodo (161). De los 86 textos completos solicitados, 7 no pudieron obtenerse. Se evaluaron 79 y se excluyeron 15:

- 9 porque la protección actúa solo en la inferencia de un modelo fijo;
- 5 porque su objetivo es exclusivamente impedir el entrenamiento de modelos generativos;
- 1 porque estudia otro fenómeno.

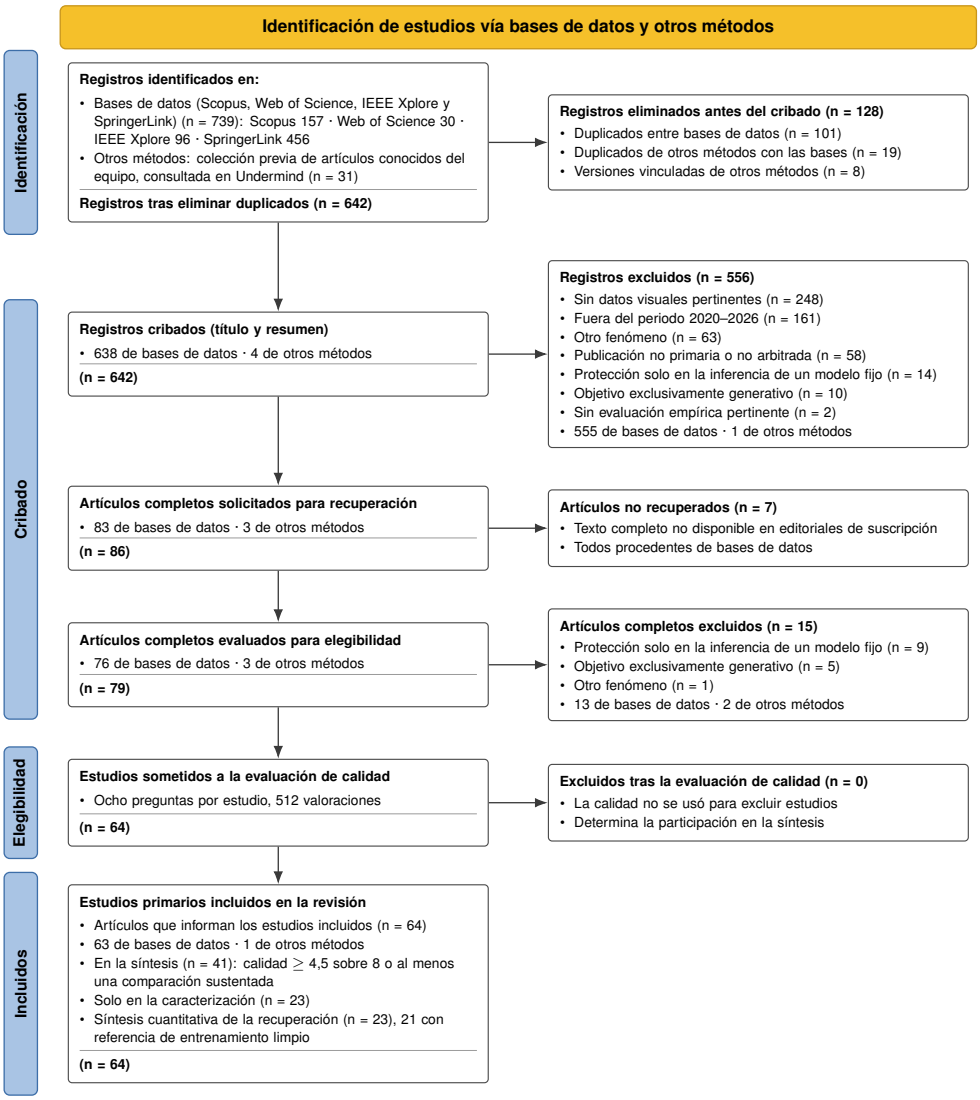


Figura 1 Diagrama de flujo PRISMA 2020 de la selección de estudios

De los 64 estudios incluidos, 41 participaron en la síntesis y 23 aportaron comparaciones sustentadas a la síntesis cuantitativa de la recuperación.

4.1. Distribución de las publicaciones

Los estudios incluidos se publicaron entre 2020 y 2026 (Fig. 2). El número de publicaciones aumentó a partir de 2023: el 79,7 % de los estudios se publicó entre 2023 y 2025. El valor de 2026 corresponde a un año incompleto, ya que la búsqueda se realizó en octubre.

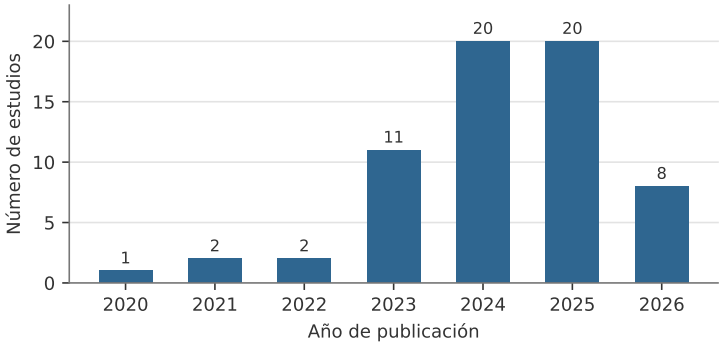


Figura 2 Distribución de los estudios incluidos por año de publicación

Los 64 estudios se publicaron en 33 sedes distintas (Tabla 10). El 84,4 % son ponencias de congreso y el 15,6 %, artículos de revista. Siete sedes reúnen más de un estudio y concentran el 59,4 % del total:

- la International Conference on Learning Representations, 7 estudios;
- Advances in Neural Information Processing Systems, 6;
- Lecture Notes in Computer Science, 6;
- la AAAI Conference on Artificial Intelligence, 5;
- la IEEE/CVF Conference on Computer Vision and Pattern Recognition, 5;
- Proceedings of Machine Learning Research, 5;
- la ACM International Conference on Multimedia, 4.

Ninguna revista publicó más de un estudio.

4.2. Calidad de los estudios

La valoración de la calidad tuvo una media de 4,16 y una mediana de 4,0 sobre 8, con un rango de 1,5 a 7,0. La Tabla 11 muestra que la mayoría de los aspectos se resolvió como cumplimiento parcial. La validez de las métricas fue el aspecto mejor valorado (48 estudios con Sí). La separación entre desarrollo y prueba y la incertidumbre de los resultados concentraron la información insuficiente, con 27 y 36 estudios respectivamente. Solo tres estudios informaron la incertidumbre de forma completa [9, 23, 51]. De los 41 estudios que participaron en la síntesis, 18 lo hicieron por su valoración de calidad, 11 por aportar comparaciones sustentadas y 12 por ambos motivos.

4.3. RQ1: ¿Qué estrategias y algoritmos de perturbación proactiva se han propuesto, cómo se caracterizan y en qué tareas, conjuntos de datos y arquitecturas se han evaluado?

De los 64 estudios, 43 proponen una protección, 18 proponen o evalúan una contramedida y 3 son análisis o bancos de pruebas [22, 51, 69]. Las 43 protecciones se

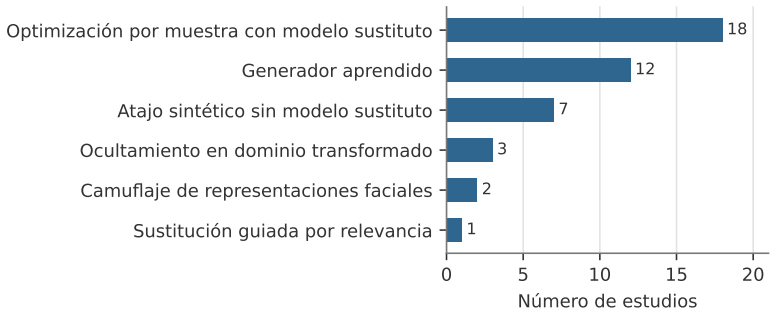


Figura 3 Número de protecciones por estrategia de generación

agruparon en seis estrategias de generación (Tabla 12 y Fig. 3). El 69,8 % de ellas requiere entrenar un modelo sustituto o un generador.

Tabla 12: Estrategias de protección propuestas en los estudios incluidos

Protección	Estudio	Modalidad	Tarea
Optimización por muestra con un modelo sustituto (18 estudios; requiere un modelo sustituto)			
Minimización del error (ejemplos no aprendibles)	[1]	Imagen 2D	Clasificación
Minimización del error robusta al entrenamiento adversario	[2]	Imagen 2D	Clasificación
Ruido minimizador del error estable	[3]	Imagen 2D	Clasificación
Optimización min-max-min con sustituto entrenado adversarialmente	[42]	Imagen 2D	Clasificación
Minimización del error adaptada a aumentos de datos	[49]	Imagen 2D	Clasificación
ARMOR, con aumento sustituto y alineación de gradientes	[65]	Imagen 2D	Clasificación
Ejemplos no aprendibles reversibles mediante información mutua y marca de agua	[63]	Imagen 2D	Clasificación
Ejemplos no aprendibles y envenenamiento adversarial aumentados	[25]	Imagen 2D	Clasificación
Minimización del error con colisión de rasgos	[10]	Nube de puntos 3D	Clasificación
Envenenamiento contrastivo	[7]	Imagen 2D	Clasificación
Minimización del error en varios pasos	[8]	Imagen-texto	Recuperación imagen-texto
Minimización del error en varios pasos con refinamiento conjunto	[50]	Imagen-texto	Recuperación imagen-texto
Perturbación con rasgos dominantes de otra clase	[66]	Imagen 2D	Clasificación
Maximización del error de Bayes	[35]	Imagen 2D	Clasificación
Ejemplos no generalizables con red autorizada	[40]	Imagen 2D	Clasificación
Máscara de aprendibilidad personalizable	[56]	Imagen 2D	Clasificación
Optimización en el espacio latente de un autocodificador de difusión	[30]	Imagen 2D	Clasificación
Ejemplos no aprendibles transferibles	[21]	Imagen 2D	Clasificación
Generador aprendido (12 estudios; requiere entrenar un generador)			
Agrupamientos no aprendibles sin etiquetas	[39]	Imagen 2D	Clasificación
Agrupamientos no aprendibles con cómputo distribuido	[55]	Imagen 2D	Clasificación
Generador para reconocimiento facial de conjunto abierto	[62]	Imagen facial	Reconocimiento facial
Generador guiado por información lateral	[52]	Imagen facial	Reconocimiento facial
Generador a partir de descripciones textuales	[46]	Imagen-texto	Recuperación imagen-texto

Tabla 12 (continuación)

Protección	Estudio	Modalidad	Tarea
Generador transferible entre dominios	[26]	Imagen 2D	Clasificación
Generador universal por concepto mediante alineación multimodal	[43]	Imagen 2D	Clasificación
Generador para aprendizaje multitarea	[44]	Imagen 2D	Multitarea
Generador universal para segmentación	[27]	Imagen 2D	Segmentación
Generador basado en teoría de juegos	[37]	Imagen 2D	Clasificación
Generador temporal para seguimiento de objetos	[54]	Vídeo	Seguimiento de objetos
Disrupción espectral entre cortes	[58]	Volumen médico 3D	Segmentación
Atajo sintético sin modelo sustituto (7 estudios; no requiere modelo)			
Convolución con filtros aleatorios por clase	[4]	Imagen 2D	Clasificación
Atajo de un único píxel	[5]	Imagen 2D	Clasificación
Perturbaciones sintéticas separables por clase	[6]	Imagen 2D	Clasificación
Convolución por clase combinada con cambio de un píxel	[61]	Imagen 2D	Clasificación
Restauración imperfecta de filtros convolucionales	[34]	Imagen 2D	Clasificación
Transformaciones geométricas por clase	[9]	Nube de puntos 3D	Clasificación
Patrón único de Fourier asociado a la presencia de objetos	[57]	Imagen 2D	Detección de objetos
Ocultamiento en dominio transformado (3 estudios; requiere redes de ocultamiento)			
Esteganografía en el biespectro del espacio k	[45]	Imagen 2D	Clasificación
Esteganografía en el dominio de ondículas	[68]	Imagen 2D	Clasificación
Ocultamiento semántico mediante redes invertibles	[64]	Imagen 2D	Clasificación
Camuflaje de representaciones faciales (2 estudios; requiere un extractor facial)			
Camuflaje de rasgos faciales hacia otra identidad	[11]	Imagen facial	Reconocimiento facial
Camuflaje de rasgos faciales con extractor propio	[48]	Imagen facial	Reconocimiento facial
Sustitución guiada por relevancia (1 estudio; requiere el clasificador objetivo)			
Sustitución de regiones según la relevancia por capas	[60]	Imagen 2D	Clasificación

Optimización por muestra con un modelo sustituto.

Es la estrategia más frecuente, con 18 estudios. Su forma básica es la minimización bi-nivel del error: se optimiza un ruido que reduce la pérdida de un modelo sustituto, de modo que el modelo aprende el ruido y no el contenido [1]. Sobre esta base se han propuesto variantes en varias direcciones:

- robustas al entrenamiento adversario, mediante optimizaciones de tres niveles o sustitutos entrenados adversarialmente [2, 3, 42];
- que incorporan los aumentos de datos en la generación [49, 65];
- adaptadas al aprendizaje contrastivo [7, 21, 25] y a los modelos imagen-texto [8, 50].

Otros estudios sustituyen el objetivo de minimización por la maximización del error de Bayes [35], la alineación de gradientes con una red autorizada [40] o la optimización en el espacio latente de un autocodificador de difusión [30].

Generadores aprendidos.

Doce estudios entrenan una red que produce la perturbación, lo que evita optimizar cada muestra y permite escalar a grandes conjuntos o transferir la protección entre tareas. Los generadores se han aplicado a:

- escenarios sin etiquetas [39, 55];
- reconocimiento facial [52, 62];
- generación guiada por texto [43, 46];
- transferencia entre dominios [26];
- aprendizaje multitarea [44];
- segmentación [27, 58];
- seguimiento de objetos en vídeo [54].

Uno de ellos se formula como un juego entre el protector y el aprendiz [37].

Atajos sintéticos sin modelo sustituto.

Siete estudios inducen una correlación espuria entre un patrón simple y la clase, sin entrenar ningún modelo. Los patrones son:

- filtros convolucionales aleatorios por clase [4];
- un único píxel [5];
- ruido separable por clase [6];
- combinaciones de convolución y cambio de un píxel [34, 61];
- transformaciones geométricas por clase en nubes de puntos [9];
- patrones de Fourier para detección de objetos [57].

Otras estrategias.

Tres estudios ocultan una señal asociada a la clase en un dominio transformado, mediante esteganografía en frecuencia [45, 68] o redes invertibles [64]. Dos estudios camuflan los rasgos faciales para desplazarlos hacia otra identidad [11, 48]. Un estudio sustituye regiones de la imagen según su relevancia para el clasificador [60].

Escenarios de evaluación.

Considerando los 64 estudios, la modalidad dominante es la imagen 2D (49 estudios). Le siguen la imagen facial (6), los pares imagen-texto (5), las nubes de puntos (2), el vídeo (1) y los volúmenes médicos (1). La tarea más evaluada es la clasificación (48 estudios), seguida del reconocimiento facial (6) y la recuperación imagen-texto (4). CIFAR-10 se utilizó en 46 estudios, los subconjuntos de ImageNet en 38 y CIFAR-100 en 36. Las arquitecturas más frecuentes fueron ResNet-18 (45 estudios), DenseNet (33), ResNet-50 (31) y VGG (30); los transformadores de visión aparecen en 16 estudios.

Recuperación autorizada.

Solo cuatro estudios evalúan una vía para que un actor legítimo restituya la aprendibilidad: una red autorizada [40], un limpiador entregado por el titular [56], marcas de agua reversibles [63] o los parámetros de las transformaciones por clase [9]. En el resto de los estudios, la reversibilidad se examina solo desde la perspectiva del adversario.

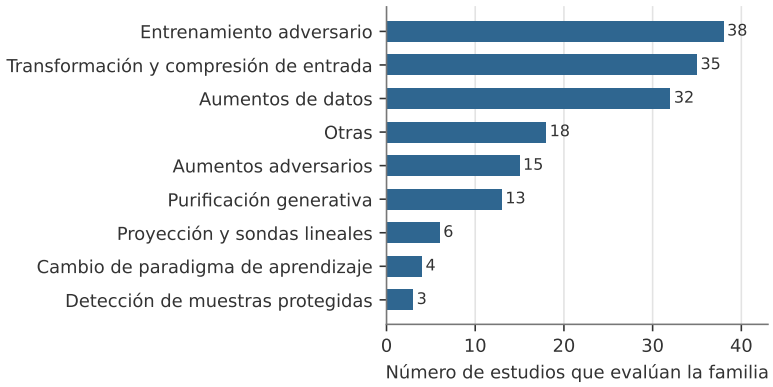


Figura 4 Número de estudios que evalúan cada familia de contramedida

4.4. RQ2: ¿Qué contramedidas se han evaluado frente a estas protecciones y bajo qué conocimientos, capacidades, acceso y recursos del adversario?

Cincuenta y seis estudios evalúan al menos una contramedida. Los ocho restantes presentan la protección sin probarla frente a contramedidas [8, 21, 50, 54–56, 58, 62]. La Tabla 13 y la Fig. 4 resumen las familias evaluadas. Las tres más frecuentes son:

- el entrenamiento adversario, en 38 estudios;
- la transformación y compresión de la entrada, en 35;
- los aumentos de datos convencionales, en 32.

Les siguen los aumentos adversarios (15 estudios) y la purificación generativa (13). La proyección y las sondas lineales, el cambio del paradigma de aprendizaje y la detección de muestras protegidas aparecen en seis estudios o menos. El número de familias por estudio varía de forma considerable: 14 estudios evalúan una sola y 17, cuatro o más.

El modelo de adversario se describe con niveles de detalle distintos. Los escenarios van:

- desde un aprendiz que recibe los datos protegidos con sus etiquetas y controla el entrenamiento [6, 66];
- pasando por un aprendiz que desconoce qué muestras están protegidas [15, 29];
- hasta un adversario con conocimiento completo de la protección [32] o que trata al protector como una caja negra con acceso a consultas [28].

Siete estudios no declaran qué conoce el adversario sobre la protección.

Las contramedidas de purificación suponen recursos adicionales: un modelo de difusión preentrenado [13, 14], una pequeña muestra de datos limpios para entrenar el purificador [31] o pares de datos protegidos y limpios obtenidos por fuga de la protección [28]. Varios estudios de protección generan perturbaciones adaptadas a una contramedida conocida, como el entrenamiento adversario o los aumentos de datos [2, 3, 49, 65], y evalúan la protección frente a esa misma contramedida.

4.5. RQ3: ¿Qué grado de protección persiste y qué recuperación del rendimiento logra el adversario tras aplicar las contramedidas evaluadas?

De las 7025 comparaciones entre la condición protegida y la condición con contramedida extraídas de 57 estudios, el 44,8 % tuvo comparabilidad sustentada, el 50,7 % comparabilidad limitada y el 4,4 % comparabilidad no determinable. La síntesis cuantitativa se basa en 3070 comparaciones sustentadas con resultado calculable, procedentes de 23 estudios. Veintidós de ellos evalúan clasificación de imagen 2D y uno, aprendizaje de prompts sobre un modelo imagen-texto [41].

En el conjunto de la síntesis, la mediana de la recuperación del adversario fue de 26,4 pp de exactitud (rango intercuartílico entre estudios: 8,0–34,3) y la brecha mediana al entrenamiento limpio, de 37,0 pp. En promedio, el 12,6 % de las comparaciones de cada estudio quedó a 5 pp o menos del entrenamiento limpio (5,3 % con un umbral de 2 pp y 24,7 % con uno de 10 pp). En 547 comparaciones de 19 estudios, la contramedida redujo el rendimiento en lugar de recuperarlo. Excluir los dos estudios con más comparaciones [12, 64], que reúnen el 44,8 % del total, no modificó la mediana (26,5 pp).

Recuperación por familia de contramedida.

La Tabla 14 y la Fig. 5 desagregan los resultados por familia:

- La purificación generativa alcanzó la mayor recuperación, con una mediana de 66,8 pp y una brecha de 7,9 pp al entrenamiento limpio, en tres estudios [15, 28, 31].
- El entrenamiento adversario (10 estudios) y la transformación y compresión de la entrada (12 estudios) obtuvieron recuperaciones intermedias, de 25,9 y 25,0 pp, con brechas de 39,1 y 23,9 pp.
- Los aumentos de datos convencionales (8 estudios) recuperaron 4,7 pp y dejaron la mayor brecha, de 66,4 pp.

Las familias evaluadas en uno o dos estudios se presentan para completar la descripción.

Recuperación por tipo de protección.

La Tabla 15 cruza la familia de contramedida con el tipo de protección evaluada:

- La purificación generativa obtuvo recuperaciones similares, entre 64,1 y 67,0 pp, frente a las protecciones por minimización del error, por maximización del error y por atajos sintéticos.
- El entrenamiento adversario recuperó 58,7 pp frente a la maximización del error (6 estudios), 41,6 pp frente a la minimización del error (8 estudios) y 22,3 pp frente a los atajos sintéticos (8 estudios).
- Los aumentos de datos recuperaron menos de 5 pp frente a los tres tipos de protección.
- Frente al envenenamiento contrastivo, el entrenamiento adversario (dos estudios) y la transformación de la entrada (tres estudios) obtuvieron medianas negativas.

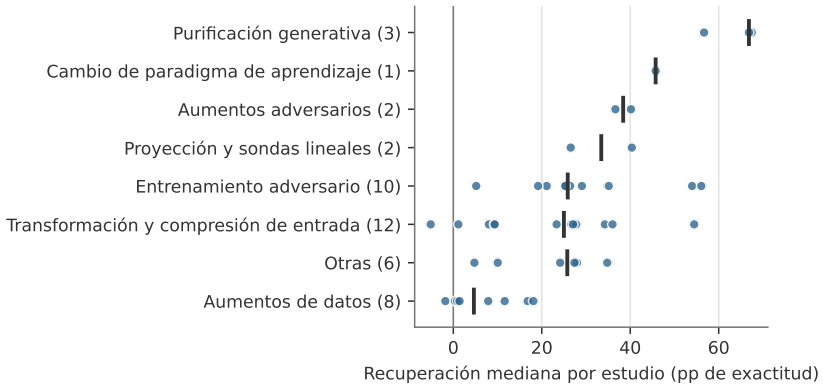


Figura 5 Recuperación mediana por estudio según la familia de contramedida. Cada punto es un estudio y la línea vertical indica la mediana entre estudios; entre paréntesis, número de estudios

Recuperación según la orientación del estudio.

Los estudios que proponen o evalúan una contramedida informaron una recuperación mediana de 34,3 pp y una brecha de 13,3 pp al entrenamiento limpio, con el 27 % de sus comparaciones a 5 pp o menos de él (Tabla 16). Los estudios que proponen una protección informaron una recuperación de 15,7 pp, una brecha de 47,9 pp y un 4 % de comparaciones próximas al entrenamiento limpio. La composición de las familias evaluadas difiere entre ambos grupos: los estudios de protección evalúan sobre todo aumentos de datos, entrenamiento adversario y transformaciones de la entrada, mientras que todas las purificaciones generativas proceden de estudios de contramedida.

Precisión de los resultados.

De los 23 estudios de la síntesis cuantitativa:

- 13 no informan la incertidumbre de sus resultados;
- 5 la informan de forma insuficiente;
- 4 la informan de forma parcial;
- 1 la informa de forma completa.

El Apéndice A presenta los resultados de cada estudio.

4.6. RQ4: ¿Qué referencias experimentales y métricas se utilizan para evaluar la robustez y la reversión adversaria, y en qué condiciones permiten comparar los resultados?

La Tabla 17 resume las condiciones experimentales y las métricas informadas. La exactitud de clasificación sobre datos de prueba limpios es la métrica principal en 54 estudios. Se complementa con métricas de calidad perceptual en 12 estudios, de detección en 7, de recuperación imagen-texto en 5 y de segmentación o detección de objetos en 5. Ningún estudio define un umbral a partir del cual la protección se considere suficiente o neutralizada.

La condición protegida sin contramedida se informa en 62 estudios, el entrenamiento limpio en 55 y la condición con contramedida en 55. En cambio, el entrenamiento limpio con la misma contramedida solo se informa en 32. De los 55 estudios con condición de contramedida, 23 no informan ese control y 7 no informan el entrenamiento limpio. Cuarenta y tres estudios no indican el número de repeticiones de sus experimentos.

Los resultados comparables entre estudios se concentran en un subconjunto reducido de configuraciones. De los 23 estudios con comparaciones sustentadas, 22 evalúan clasificación de imagen 2D, 21 utilizan CIFAR-10 y ResNet-18, y 20 incluyen subconjuntos de ImageNet. El 55,2 % de las comparaciones extraídas no alcanzó una comparabilidad sustentada porque faltaba alguno de los elementos de equivalencia entre condiciones: el conjunto de datos, la arquitectura, el protocolo de entrenamiento, la métrica o la especificación de la contramedida.

5. Discusión

Esta sección interpreta los resultados de la Sección 4 para cada pregunta de investigación. También examina sus implicaciones para la evaluación de las protecciones.

5.1. RQ1: estrategias de protección

La investigación se concentra en protecciones que dependen de un modelo, ya sea un sustituto optimizado por muestra o un generador entrenado. Esta dependencia tiene una consecuencia para la robustez: la protección queda ligada a la arquitectura, los datos y el régimen de entrenamiento con que se generó, y su transferencia a otros aprendices debe demostrarse en cada caso. Los atajos sintéticos evitan esa dependencia y tienen un costo de generación menor. Sin embargo, su patrón es simple y regular, lo que en principio facilita que una contramedida lo identifique [36].

La ampliación a reconocimiento facial, pares imagen-texto, vídeo y datos tridimensionales es reciente y se apoya en pocos estudios por dominio. Por ello, la caracterización de esos dominios es todavía descriptiva. La recuperación autorizada, examinada en solo cuatro estudios, es la dimensión menos desarrollada, pese a que condiciona la utilidad práctica de la protección para quien sí tiene derecho a usar los datos.

5.2. RQ2: contramedidas y modelo de adversario

Las contramedidas más evaluadas, como el entrenamiento adversario, las transformaciones de la entrada y los aumentos de datos, son también las más fáciles de aplicar y las que menos recursos suponen. La purificación generativa, que la síntesis identifica como la más eficaz, se evalúa en menos estudios y requiere recursos que pocos modelos de adversario contemplan, como un modelo de difusión preentrenado o una muestra de datos limpios. Esta asimetría tiene una consecuencia directa: una protección evaluada solo frente a las contramedidas convencionales no aporta evidencia sobre un adversario con acceso a modelos generativos, que hoy es un escenario verosímil.

Que siete estudios no declaren qué conoce el adversario sobre la protección limita la interpretación de sus resultados. La recuperación de una contramedida depende de si el adversario conoce la familia de la protección, sus parámetros o la existencia misma de la protección. Las protecciones adaptadas a una contramedida conocida responden a un escenario en el que el titular anticipa al adversario. Su evaluación frente a esa misma contramedida no indica cómo se comportan frente a otras.

5.3. RQ3: persistencia de la protección y recuperación del adversario

Entre las comparaciones interpretables, la protección rara vez se neutraliza por completo, pero tampoco persiste intacta. El adversario recupera una mediana de 26 pp y el rendimiento queda a 37 pp del entrenamiento limpio. Esta posición intermedia no permite calificar las protecciones como robustas en general, porque el resultado depende de la contramedida.

La purificación generativa deja las protecciones evaluadas a 8 pp del entrenamiento limpio. Su eficacia es similar frente a los tres tipos principales de protección, lo que sugiere que actúa eliminando la perturbación con independencia de su mecanismo. En cambio, los aumentos de datos convencionales apenas afectan a ninguna protección. Una explicación posible es que varias protecciones incorporan los aumentos en su generación [49, 65]; esta revisión no permite comprobarla.

El entrenamiento adversario muestra una dependencia clara del tipo de protección: recupera más frente a la maximización del error que frente a la minimización del error, y menos frente a los atajos sintéticos. Este patrón es coherente con que el entrenamiento adversario contrarresta perturbaciones cuyo efecto depende de la sensibilidad del modelo a cambios acotados en la entrada. Los atajos sintéticos, en cambio, operan como correlaciones espurias que no requieren esa sensibilidad. La explicación es una hipótesis y no se contrastó en los estudios incluidos.

La diferencia entre los estudios que proponen contramedidas y los que proponen protecciones es el hallazgo con mayores implicaciones metodológicas. Los primeros informan el doble de recuperación que los segundos. Varias explicaciones son compatibles con este resultado y no son excluyentes:

- las familias de contramedida evaluadas difieren entre los dos grupos;
- los estudios de contramedida pueden emplear protecciones de referencia más débiles;
- los estudios de protección pueden presentar versiones ajustadas a las contramedidas que ellos mismos evalúan;
- cada grupo puede informar preferentemente los resultados que favorecen su contribución.

La revisión no permite separarlas. En cualquier caso, la robustez de una protección no puede establecerse solo a partir de la evaluación de sus autores.

5.4. RQ4: referencias experimentales y comparabilidad

La exactitud de clasificación ofrece una base común de medición, pero las referencias que la acompañan no son homogéneas. La omisión del entrenamiento limpio con

la misma contramedida, presente en 23 de los 55 estudios con contramedida, impide separar dos componentes de la pérdida remanente: la que se debe a la protección y la que causa la propia contramedida. La ausencia de un umbral operativo deja sin criterio la pregunta de cuándo una protección falla. Que 43 estudios no informen repeticiones impide valorar si las diferencias pequeñas dentro de un estudio superan la variación entre ejecuciones.

Los resultados de esta revisión sugieren un conjunto mínimo de elementos de reporte que haría comparables los estudios:

1. informar siempre el entrenamiento limpio, el protegido, el protegido con contramedida y el limpio con la misma contramedida, bajo el mismo protocolo;
2. especificar por completo cada contramedida, con sus parámetros, su presupuesto, el número de épocas y los datos auxiliares que emplea;
3. declarar el conocimiento y los recursos del adversario, en particular el acceso a modelos generativos y a datos limpios;
4. informar el número de repeticiones y una medida de dispersión;
5. definir un umbral operativo de protección suficiente, por ejemplo una brecha mínima aceptable respecto del entrenamiento limpio;
6. evaluar las protecciones frente a contramedidas de terceros o frente a un conjunto común, como el que propone APBench [69].

Estos elementos derivan de las deficiencias observadas y no se validaron empíricamente en esta revisión.

5.5. Comparación con revisiones previas

Las revisiones existentes señalan la robustez como un desafío abierto [16, 17]. Esta revisión precisa la magnitud de ese desafío bajo un criterio explícito de comparabilidad y muestra que depende de la familia de contramedida, del tipo de protección y de quién realiza la evaluación. La restricción a las comparaciones sustentadas descartó el 55,2 % de los resultados extraídos, cuya diferencia no podía atribuirse a la contramedida. Una agregación sin ese filtro habría mezclado efectos de la contramedida con diferencias de protocolo.

6. Amenazas a la validez

Validez de constructo.

La recuperación se midió casi siempre como exactitud de clasificación. Esta medida no captura otros usos de los datos protegidos, como la extracción de representaciones o el ajuste fino, ni la restauración del dato original. La agrupación de protecciones y contramedidas es una construcción de esta revisión. Cuando una condición combinaba varias contramedidas, la regla de asignación pudo ubicarla en una familia distinta de la que sus autores consideran principal.

Validez interna.

En la etapa de elegibilidad, el segundo revisor no releyó los textos completos: contrastó cada decisión con la ficha de extracción y el acta de revisión. Este procedimiento

reduce la independencia de esa decisión. La evaluación de la calidad la realizó un solo revisor por estudio. Los juicios de comparabilidad requieren interpretar recetas de entrenamiento a veces incompletas, lo que introduce un componente subjetivo. [Indicar el alcance de la verificación de la extracción por un segundo revisor.]

Validez externa.

La síntesis cuantitativa procede casi exclusivamente de la clasificación de imagen 2D, con predominio de CIFAR-10 y ResNet-18. Sus resultados no se extienden al vídeo, a los datos tridimensionales, al reconocimiento facial ni a los modelos de gran escala. La exclusión de las preimpresiones sin publicación arbitrada deja fuera trabajos citados en el área, y siete textos completos no pudieron obtenerse.

Validez de las conclusiones.

Dos estudios aportan el 44,8 % de las comparaciones de la síntesis cuantitativa. La agregación por estudio mitiga ese peso y el análisis sin ellos no cambió la mediana, pero varias familias y combinaciones se basan en uno a tres estudios. La escasez de medidas de dispersión impide estimar la precisión de las diferencias. La búsqueda se limitó a cuatro bases de datos y a una colección previa del equipo, sin búsqueda manual en las actas de los congresos de aprendizaje automático, donde se publica la mayor parte de los estudios del área.

7. Conclusiones

Esta revisión sistemática examinó la robustez y la reversibilidad de las perturbaciones proactivas frente a las contramedidas adversarias en el entrenamiento no autorizado de modelos discriminativos. Se siguieron las directrices de Kitchenham y Charters y la declaración PRISMA 2020. De 770 registros identificados en cuatro bases de datos y una colección previa, se seleccionaron 64 estudios primarios publicados entre 2020 y 2026, y se sintetizaron 3070 comparaciones con comparabilidad sustentada de 23 de ellos.

Las protecciones propuestas dependen mayoritariamente de un modelo sustituto o de un generador y se evalúan sobre todo en clasificación de imagen 2D. Frente a las contramedidas evaluadas, el adversario recupera una mediana de 26 pp de exactitud y el rendimiento queda a 37 pp del entrenamiento limpio. La purificación generativa casi neutraliza las protecciones, con independencia de su mecanismo, mientras que los aumentos de datos convencionales apenas las afectan. El entrenamiento adversario es eficaz frente a las protecciones por maximización del error y lo es poco frente a los atajos sintéticos. Los estudios que proponen contramedidas informan el doble de recuperación que los que proponen protecciones.

La evidencia disponible no permite afirmar que las protecciones actuales sean robustas frente a un adversario con acceso a modelos generativos. La comparación entre estudios está limitada por la omisión frecuente del entrenamiento limpio con la misma contramedida, de la especificación completa de las contramedidas, de las repeticiones y de cualquier umbral operativo. El trabajo futuro debería:

- evaluar las protecciones frente a contramedidas de terceros y bajo un conjunto común de condiciones;
- extender la evidencia cuantitativa al vídeo, a los datos tridimensionales y a los modelos multimodales;
- desarrollar la recuperación autorizada, que hoy se examina en muy pocos estudios.

Tabla 10 Estudios incluidos por sede de publicación

Sede de publicación	Estudios	n	Tipo
International Conference on Learning Representations (ICLR)	[1, 2, 5, 7, 21–23]	7	Congreso
Advances in Neural Information Processing Systems (NeurIPS)	[9, 24–28]	6	Congreso
Lecture Notes in Computer Science	[29–34]	6	Congreso
AAAI Conference on Artificial Intelligence	[3, 35–38]	5	Congreso
IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)	[4, 39–42]	5	Congreso
Proceedings of Machine Learning Research	[10, 12, 15, 43, 44]	5	Congreso
ACM International Conference on Multimedia (ACM MM)	[8, 14, 45, 46]	4	Congreso
2023 14th International Conference on Information and Communication Technology and System, ICTS 2023	[47]	1	Congreso
2025 11th IEEE International Conference on Privacy Computing and Data Security, PCDS 2025	[48]	1	Congreso
2025 5th Intelligent Cybersecurity Conference, ICSC 2025	[49]	1	Congreso
2025 5th International Conference on Robotics, Automation and Intelligent Control, ICRAIC 2025	[50]	1	Congreso
Frontiers in Artificial Intelligence and Applications	[51]	1	Congreso
ICASSP, IEEE International Conference on Acoustics, Speech and Signal Processing - Proceedings	[52]	1	Congreso
IEEE Conference on Safe and Trustworthy Machine Learning, SaTML 2024	[13]	1	Congreso
IEEE Congress on Cybermatics	[53]	1	Congreso
IEEE/CVF International Conference on Computer Vision (ICCV)	[54]	1	Congreso
IS and T International Symposium on Electronic Imaging Science and Technology	[55]	1	Congreso
International Conference on Computer Communications and Networks, ICCCN	[56]	1	Congreso
International Conference on Image Processing, ICIP	[57]	1	Congreso
Medical Image Computing and Computer Assisted Intervention – MICCAI 2026	[58]	1	Congreso
Proceedings of the 29th USENIX Security Symposium	[11]	1	Congreso
Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining	[6]	1	Congreso
Proceedings of the IEEE International Conference on Trust, Security and Privacy in Computing and Communications, TrustCom	[59]	1	Congreso
Applied Sciences	[60]	1	Revista
Computer Vision and Image Understanding	[61]	1	Revista
IEEE Signal Processing Letters	[62]	1	Revista
IEEE Transactions on Circuits and Systems for Video Technology	[63]	1	Revista
IEEE Transactions on Information Forensics and Security	[64]	1	Revista
IEEE Transactions on Pattern Analysis and Machine Intelligence	[65]	1	Revista
Information Sciences	[66]	1	Revista
Neurocomputing	[67]	1	Revista
Pattern Recognition	[68]	1	Revista
Transactions on Machine Learning Research	[69]	1	Revista

Tabla 11 Resultados de la evaluación de la calidad de los 64 estudios incluidos

Aspecto evaluado	Sí	Parcial	No	Información insuficiente
Descripción de la protección y la contramedida	14	50	0	0
Identificación de datos y modelos	15	48	1	0
Separación entre desarrollo y prueba	8	21	8	27
Adecuación de los comparadores	6	55	3	0
Validez de las métricas	48	16	0	0
Incertidumbre de los resultados	3	14	11	36
Reporte completo	10	52	2	0
Mesura de las conclusiones	8	53	3	0

Tabla 13 Familias de contramedidas evaluadas en los estudios incluidos (un estudio puede evaluar varias familias)

Familia	Contramedidas representativas	Estudios	n
Entrenamiento adversario	Entrenamiento adversario PGD con normas ℓ_∞ y ℓ_2, TRADES, aprendizaje contrastivo adversario	[1–5, 7, 10–12, 14, 15, 22, 24–28, 30, 31, 33–38, 41, 42, 45, 49, 52, 53, 61, 63–66, 68, 69]	38
Transformación y compresión de entrada	Compresión JPEG, escala de grises, reducción de profundidad de bits, filtros de media, mediana y gaussiano, compresión de atajos	[2–4, 7, 9, 11, 12, 14, 15, 22, 23, 25, 27, 30, 31, 33, 34, 36, 38, 39, 41, 43–45, 48, 52, 53, 57, 60, 61, 63, 64, 67–69]	35
Aumentos de datos	Cutout, Mixup, CutMix, AutoAugment, RandAugment	[1, 4–7, 10–12, 14, 15, 22, 25, 26, 28, 31, 33, 34, 36, 37, 39, 43, 45, 46, 49, 52, 53, 63–66, 68, 69]	32
Aumentos adversarios	Aumentos adversarios, borrado de ejemplos no aprendibles mediante aumentos fuertes	[14, 15, 22, 25, 26, 30, 31, 34, 36, 38, 41, 61, 63, 64, 69]	15
Purificación generativa	Purificación con modelos de difusión, autocodificadores variacionales y puentes de difusión	[13–15, 25, 26, 28, 29, 31, 34, 36, 59, 64, 69]	13
Proyección y sondas lineales	Proyección ortogonal, reentrenamiento de la capa final, sondas lineales	[24, 31, 36, 43, 51, 64]	6
Cambio de paradigma de aprendizaje	Aprendizaje autosupervisado o contrastivo, combinación de pérdidas supervisada y autosupervisada, ensambles	[25, 33, 64, 67]	4
Detección de muestras protegidas	Filtrado iterativo, detectores de camuflaje, redes simples de detección	[11, 29, 47]	3
Otras	Entrenamiento con privacidad diferencial, mezcla con datos limpios, parada temprana, destilación, contramedidas específicas de un estudio	[1–4, 10, 15, 23, 28, 31, 32, 36, 40, 41, 45, 59, 63, 65, 66]	18

Tabla 14 Recuperación del rendimiento y brecha respecto del entrenamiento limpio por familia de contramedida, en puntos porcentuales de exactitud

Familia de contramedida	Estudios	Comparaciones	Recuperación	Rango intercuartílico	Brecha al entrenamiento limpio	Cercanía al entrenamiento limpio (%)
Purificación generativa	3	267	66,8	–	7,9	32
Cambio de paradigma de aprendizaje	1	79	45,7	–	14,4	19
Aumentos adversarios	2	31	38,4	–	33,9	0
Proyección y sondas lineales	2	38	33,5	–	35,9	4
Entrenamiento adversario	10	411	25,9	20,6–39,9	39,1	3
Transformación y compresión de entrada	12	1248	25,0	8,3–32,6	23,9	15
Otras	6	354	25,8	8,7–29,7	41,3	16
Aumentos de datos	8	642	4,7	0,5–15,5	66,4	4

Recuperación y brecha: mediana de las medianas por estudio. El rango intercuartílico se informa con cuatro o más estudios. Cercanía: porcentaje medio, por estudio, de comparaciones que quedan a 5 puntos o menos del entrenamiento limpio.

Tabla 15 Recuperación del rendimiento según el tipo de protección evaluada y la familia de contramedida, en puntos porcentuales de exactitud

Tipo de protección	Purificación generativa	Aumentos adversarios	Entrenamiento adversario	Transformación y compresión	Aumentos de datos	Proyección y sondas lineales	Cambio de paradigma
Minimización del error	64,1 (3)	35,7 (2)	41,6 (8)	22,7 (8)	4,0 (7)	27,9 (2)	[55,9]
Maximización del error	66,3 (3)	[42,4]	58,7 (6)	34,8 (6)	1,5 (4)	29,3 (2)	[64,8]
Atajos sintéticos sin modelo sustituto	67,0 (3)	42,8 (2)	22,3 (8)	20,8 (9)	4,4 (6)	33,4 (2)	[39,1]
Envenenamiento contrastivo	–	–	−5,2 (2)	−11,4 (3)	[0,2]	–	[−4,4]

Tabla 16 Recuperación del rendimiento y brecha respecto del entrenamiento limpio según la orientación del estudio, en puntos porcentuales de exactitud

Orientación del estudio	Estudios	Comparaciones	Recuperación	Rango intercuartílico	Brecha al entrenamiento limpio	Cercanía al entrenamiento limpio (%)
Proponen una protección	13	1585	15,7	5,0–26,6	47,9	4
Proponen o evalúan una contramedida	9	1473	34,3	24,2–57,6	13,3	27
Análisis o benchmark	1	12	26,5	–	47,9	0
Total	23	3070	26,4	8,0–34,3	37,0	13
Total sin los dos estudios con más comparaciones [12, 64]	21	1695	26,5	13,7–34,7	36,1	14

Tabla 17 Condiciones experimentales y métricas informadas en los 64 estudios incluidos

Elemento	Estudios	%
Condiciones experimentales informadas		
Entrenamiento con datos limpios	55	85,9
Entrenamiento con datos protegidos sin contramedida	62	96,9
Entrenamiento con datos protegidos y contramedida	55	85,9
Entrenamiento con datos limpios y la misma contramedida	32	50,0
Recuperación autorizada	4	6,2
Número de repeticiones informado	21	32,8
Umbral operativo de protección suficiente	0	0,0
Métricas empleadas		
Exactitud de clasificación sobre datos de prueba limpios	54	84,4
Calidad perceptual (PSNR, SSIM, LPIPS, FID)	12	18,8
Detección (AUC, tasas de falsa aceptación y rechazo, F1)	7	10,9
Recuperación imagen-texto (Recall@K, rango mediano)	5	7,8
Segmentación y detección de objetos (mIoU, mAP, Dice)	5	7,8

Información suplementaria. Cadenas de búsqueda por base de datos, registros de la selección, valoraciones de calidad, datos extraídos y comparaciones con su clasificación de comparabilidad. [Indicar el repositorio y el identificador persistente.]

Declaraciones

- **Financiamiento:** [completar].
- **Conflicto de intereses:** [completar].
- **Disponibilidad de datos:** [completar].
- **Contribuciones de los autores:** [completar].

Apéndice A Resultados por estudio

Tabla A1: Recuperación del rendimiento por estudio en la síntesis cuantitativa, en puntos porcentuales de exactitud

Estudio	Orientación	Comparaciones	Mediana	Rango	Brecha al limpio	Familia más evaluada
[64]	Protección	759	3,1	−73,7 a 80,7	49,8	Transformación y compresión de entrada
[12]	Contramedida	616	4,7	−31,3 a 94,7	47,2	Transformación y compresión de entrada
[65]	Protección	293	15,7	−7,8 a 93,2	46,0	Aumentos de datos
[28]	Contramedida	240	64,0	−4,6 a 86,1	5,1	Purificación generativa
[41]	Contramedida	228	28,0	−3,6 a 66,2	2,1	Otras
[2]	Protección	200	35,1	−2,6 a 76,3	39,1	Entrenamiento adversario
[33]	Contramedida	173	21,7	−20,5 a 74,3	23,8	Cambio de paradigma de aprendizaje
[15]	Contramedida	135	58,5	−12,6 a 84,2	14,4	Purificación generativa
[44]	Protección	119	8,0	−21,8 a 65,1	36,1	Transformación y compresión de entrada
[42]	Protección	72	26,4	−15,4 a 75,4	13,7	Entrenamiento adversario
[34]	Protección	30	26,9	−11,4 a 73,2	23,4	Entrenamiento adversario
[40]	Protección	28	4,8	−12,5 a 41,5	37,0	Otras
[4]	Protección	27	20,0	−9,3 a 32,7	53,2	Entrenamiento adversario
[24]	Contramedida	26	40,4	−1,0 a 80,3	23,9	Proyección y sondas lineales
[5]	Protección	24	18,1	−6,1 a 67,1	56,8	Aumentos de datos
[31]	Contramedida	23	56,7	−9,4 a 76,7	12,2	Purificación generativa
[36]	Contramedida	20	34,3	8,7 a 52,3	–	Transformación y compresión de entrada
[53]	Contramedida	12	26,6	14,9 a 41,5	5,9	Transformación y compresión de entrada
[63]	Protección	12	27,8	21,8 a 35,0	–	Transformación y compresión de entrada
[51]	Análisis	12	26,5	12,2 a 59,0	47,9	Proyección y sondas lineales
[61]	Protección	12	5,2	−1,7 a 18,7	69,0	Entrenamiento adversario
[6]	Protección	8	11,6	−2,9 a 37,5	66,3	Aumentos de datos
[1]	Protección	1	−1,8	−1,8 a −1,8	80,3	Aumentos de datos

Referencias

[1] Huang, H., *et al.*: Unlearnable examples: Making personal data unexploitable. In: ICLR 2021 - 9th International Conference on Learning Representations (2021)

[2] Fu, S., *et al.*: Robust unlearnable examples: Protecting data against adversarial learning. In: ICLR 2022 - 10th International Conference on Learning Representations (2022)

[3] Liu, Y.-X., *et al.*: Stable unlearnable example: Enhancing the robustness of unlearnable examples via stable error-minimizing noise. In: Proceedings of the AAAI Conference on Artificial Intelligence (2024). https://doi.org/10.1609/aaai.v38i4.28169

[4] Sadasivan, V.S., Soltanolkotabi, M., Feizi, S.: Cuda: Convolution-based unlearnable datasets. In: Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition (2023). https://doi.org/10.1109/cvpr52729.2023.00376

[5] Wu, S., *et al.*: One-pixel shortcut: On the learning preference of deep neural networks. In: 11th International Conference on Learning Representations, ICLR 2023 (2023)

[6] Yu, D., *et al.*: Availability attacks create shortcuts. In: Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (2022). https://doi.org/10.1145/3534678.3539241

[7] He, H., Zha, K.-W., Katabi, D.: Indiscriminate poisoning attacks on unsupervised contrastive learning. In: 11th International Conference on Learning Representations, ICLR 2023 (2023)

[8] Liu, X.-W., *et al.*: Multimodal unlearnable examples: Protecting data against multimodal contrastive learning. In: MM 2024 - Proceedings of the 32nd ACM International Conference on Multimedia (2024). https://doi.org/10.1145/3664647.3680708

[9] Wang, X.-L., *et al.*: Unlearnable 3d point clouds: Class-wise transformation is all you need. In: Advances in Neural Information Processing Systems (2024)

[10] Zhu, Y., *et al.*: Toward availability attacks in 3d point clouds. In: Proceedings of Machine Learning Research (2024)

[11] Shan, S., *et al.*: Fawkes: Protecting privacy against unauthorized deep learning models. In: Proceedings of the 29th USENIX Security Symposium (2020)

[12] Liu, Z., Zhao, Z., Larson, M.: Image shortcut squeezing: Countering perturbative availability poisons with compression. In: Proceedings of Machine Learning Research (2023)

[13] Dolatabadi, H.M., Erfani, S., Leckie, C.: The devil's advocate: Shattering the illusion of unexploitable data using diffusion models. In: Proceedings - IEEE Conference on Safe and Trustworthy Machine Learning, SaTML 2024 (2024).

https://doi.org/10.1109/satml59370.2024.00025

[14] Jiang, W., *et al.*: Unlearnable examples give a false sense of security: Piercing through unexploitable data with learnable examples. In: MM 2023 - Proceedings of the 31st ACM International Conference on Multimedia (2023). https://doi.org/10.1145/3581783.3611833

[15] Yu, Y., *et al.*: Purify unlearnable examples via rate-constrained variational autoencoders. In: Proceedings of Machine Learning Research (2024)

[16] Li, J., Chen, Y.-Q., Xing, Y., Gu, Y., Lan, X.: A Survey on Unlearnable Data. Preprint arXiv:2503.23536 (2025). https://doi.org/10.48550/arXiv.2503.23536

[17] Zhang, M.-Y., Wang, D.-R., Sun, R.-X., Xia, X.-Y., Hao, S., Xue, J.: SoK: Unlearnability and Unlearning for Model Dememorization. Preprint arXiv:2605.11592 (2026). https://doi.org/10.48550/arXiv.2605.11592

[18] Cinà, A.E., Grosse, K., Demontis, A., Vascon, S., Zellinger, W., Moser, B., *et al.*: Wild patterns reloaded: A survey of machine learning security against training data poisoning. ACM Computing Surveys (2022) https://doi.org/10.1145/3585385

[19] Kitchenham, B., Charters, S.: Guidelines for performing systematic literature reviews in software engineering. Technical Report EBSE-2007-01, Keele University and Durham University (2007)

[20] Page, M.J., McKenzie, J.E., Bossuyt, P.M., *et al.*: The PRISMA 2020 statement: An updated guideline for reporting systematic reviews. BMJ **372**, 71 (2021) https://doi.org/10.1136/bmj.n71

[21] Ren, J., *et al.*: Transferable unlearnable examples. In: 11th International Conference on Learning Representations, ICLR 2023 (2023)

[22] Ye, K., Su, L.-C., Qian, C.-X.: How far are we from true unlearnability? In: 13th International Conference on Learning Representations, ICLR 2025 (2025)

[23] Kumar, A., *et al.*: Provable robustness against wasserstein distribution shifts via input randomization. In: 11th International Conference on Learning Representations, ICLR 2023 (2023)

[24] Sandoval Segura, P., *et al.*: What can we learn from unlearnable datasets? In: Advances in Neural Information Processing Systems (2023)

[25] Wang, Y.-H., Zhu, Y., Gao, X.-S.: Efficient availability attacks against supervised and contrastive learning simultaneously. In: Advances in Neural Information Processing Systems (2024)

[26] Li, Z., *et al.*: Versatile transferable unlearnable example generator. In: Advances

in Neural Information Processing Systems (2025)

[27] Sun, Y., *et al.*: Unseg: One universal unlearnable example generator is enough against all image segmentation. In: Advances in Neural Information Processing Systems (2024)

[28] Wang, Y.-H., *et al.*: Bridgepure: Limited protection leakage can break black-box data protection. In: Advances in Neural Information Processing Systems (2025)

[29] Yu, Y., *et al.*: Unlearnable examples detection via iterative filtering. In: Lecture Notes in Computer Science (including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics) (2024). https://doi.org/10.1007/978-3-031-72359-9_18

[30] Meerza, S.I.A., *et al.*: Diffue: Enhancing utility-unlearnability trade-off of unlearnable examples via diffusion autoencoders. In: Lecture Notes in Computer Science (2026). https://doi.org/10.1007/978-3-032-37010-5_3

[31] Wang, X.-L., *et al.*: Eclipse: Expunging clean-label indiscriminate poisons via sparse diffusion purification. In: Lecture Notes in Computer Science (including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics) (2024). https://doi.org/10.1007/978-3-031-70879-4_8

[32] Chen, L.-Q., *et al.*: Oriole: Thwarting privacy against trustworthy deep learning models. In: Lecture Notes in Computer Science (including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics) (2021). https://doi.org/10.1007/978-3-030-90567-5_28

[33] Styborski, J., *et al.*: Exploiting supervised poison vulnerability to strengthen self-supervised defense. In: Lecture Notes in Computer Science (including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics) (2025). https://doi.org/10.1007/978-3-031-73007-8_16

[34] Huang, Y., *et al.*: Leveraging imperfect restoration for data availability attack. In: Lecture Notes in Computer Science (including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics) (2025). https://doi.org/10.1007/978-3-031-73464-9_5

[35] Zhang, R.-H., *et al.*: Towards provably unlearnable examples via bayes error optimisation. In: Proceedings of the AAAI Conference on Artificial Intelligence (2026). https://doi.org/10.1609/aaai.v40i42.40923

[36] Li, M., *et al.*: Detecting and corrupting convolution-based unlearnable examples. In: Proceedings of the AAAI Conference on Artificial Intelligence (2025). https://doi.org/10.1609/aaai.v39i17.34025

[37] Liu, S., Wang, Y.-H., Gao, X.-S.: Game-theoretic unlearnable example generator.

In: Proceedings of the AAAI Conference on Artificial Intelligence (2024). https://doi.org/10.1609/aaai.v38i19.30130

[38] Zhu, Y., Yu, L.-J., Gao, X.-S.: Detection and defense of unlearnable examples. In: Proceedings of the AAAI Conference on Artificial Intelligence (2024). https://doi.org/10.1609/aaai.v38i15.29667

[39] Zhang, J., *et al.*: Unlearnable clusters: Towards label-agnostic unlearnable examples. In: Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition (2023). https://doi.org/10.1109/cvpr52729.2023.00388

[40] Ye, J., Wang, X.: Ungeneralizable examples. In: Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition (2024). https://doi.org/10.1109/cvpr52733.2024.01135

[41] Wang, X., *et al.*: A3: Few-shot prompt learning of unlearnable examples with cross-modal adversarial feature alignment. In: Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition (2025). https://doi.org/10.1109/cvpr52734.2025.00888

[42] Fang, B., *et al.*: Re-thinking data availability attacks against deep neural networks. In: Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition (2024). https://doi.org/10.1109/cvpr52733.2024.01161

[43] Chen, C.-J., *et al.*: One for all: A universal generator for concept unlearnability via multi-modal alignment. In: Proceedings of Machine Learning Research (2024)

[44] Yu, Y., *et al.*: Mtl-ue: Learning to learn nothing for multi-task learning. In: Proceedings of Machine Learning Research (2025)

[45] Li, J., *et al.*: K-space bispectrum steganography for robust unlearnable data. In: MM 2025 - Proceedings of the 33rd ACM International Conference on Multimedia, Co-Located with MM 2025 (2025). https://doi.org/10.1145/3746027.3755349

[46] Ma, X.-J., *et al.*: T2ue: Generating unlearnable examples from text descriptions. In: MM 2025 - Proceedings of the 33rd ACM International Conference on Multimedia, Co-Located with MM 2025 (2025). https://doi.org/10.1145/3746027.3758151

[47] Merino, X., Zhou, P., King, M.C.: Unmasking the threat: Detecting cloaking attacks in facial recognition. In: 2023 14th International Conference on Information and Communication Technology and System, ICTS 2023 (2023). https://doi.org/10.1109/icts58770.2023.10330887

[48] Guo, Z., Xu, J., Xu, J.: Protecting personal privacy against unauthorized facial recognition models via image cloaking. In: Proceedings - 2025 11th IEEE International Conference on Privacy Computing and Data Security, PCDS 2025 (2025). https://doi.org/10.1109/pcds65695.2025.00017

[49] Dang, L., Hapuarachchi, T., Xiong, K.: Enhancing error-minimizing noises using data augmentation. In: 2025 5th Intelligent Cybersecurity Conference, ICSC 2025 (2025). https://doi.org/10.1109/icsc65596.2025.11140570

[50] Li, S., Zheng, J., Gao, A.: Multimodal data differential privacy algorithm and ai security verification. In: Proceedings - 2025 5th International Conference on Robotics, Automation and Intelligent Control, ICRAIC 2025 (2025). https://doi.org/10.1109/icraic67376.2025.11376501

[51] Dolatabadi, H.M., Erfani, S., Leckie, C.: Be persistent: Towards a unified solution for mitigating shortcuts in deep learning. In: Frontiers in Artificial Intelligence and Applications (2024). https://doi.org/10.3233/faia240783

[52] Zhang, Z.-L., *et al.*: Segue: Side-information guided generative unlearnable examples for facial privacy protection in real world. In: ICASSP, IEEE International Conference on Acoustics, Speech and Signal Processing - Proceedings (2025). https://doi.org/10.1109/icassp49660.2025.10889952

[53] Guo, W., *et al.*: Defense contrastive poisoning: An application of jpeg to self-supervised contrastive learning indiscriminate poisoning attacks. In: Proceedings - IEEE Congress on Cybermatics: 2024 IEEE International Conferences on Internet of Things, iThings 2024, IEEE Green Computing and Communications, GreenCom 2024, IEEE Cyber, Physical and Social Computing, CPSCom 2024, IEEE Smart Data, SmartData 2024 (2024). https://doi.org/10.1109/ithings-greencom-cpscom-smartdata-cybermatics62450.2024.00097

[54] Wu, Q.-Q., *et al.*: Temporal unlearnable examples: Preventing personal video data from unauthorized exploitation by object tracking. In: Proceedings of the IEEE International Conference on Computer Vision (2025). https://doi.org/10.1109/iccv51701.2025.01034

[55] Zhu, Y.-F., *et al.*: Scale-up unlearnable examples learning with high-performance computing. In: IS and T International Symposium on Electronic Imaging Science and Technology (2025). https://doi.org/10.2352/ei.2025.37.12.hpci-184

[56] Xu, H., Shu, T.: Hide-and-seek: Data sharing with customizable machine learnability and privacy. In: Proceedings - International Conference on Computer Communications and Networks, ICCCN (2024). https://doi.org/10.1109/icccn61486.2024.10637601

[57] Yi, C.-Y., *et al.*: Towards effective and robust unlearnable examples against object detection. In: Proceedings - International Conference on Image Processing, ICIP

(2025). https://doi.org/10.1109/icip55913.2025.11084567

[58] Liu, X., *et al.*: Voxshield: Protecting 3d medical datasets from unauthorized training via frequency-aware inter-slice disruption. In: Medical Image Computing and Computer Assisted Intervention – MICCAI 2026 (2026). https://doi.org/10.1007/978-3-032-38260-3_62

[59] Li, R., *et al.*: Cross-modal collaborative recovery: Breaking multimodal unlearnable examples protection. In: Proceedings of the IEEE International Conference on Trust, Security and Privacy in Computing and Communications, TrustCom (2025). https://doi.org/10.1109/trustcom66490.2025.00185

[60] Park, Y., Kim, S., Joe, I.: A predictable-image solution for copyright protection based on layer-wise relevance propagation. Applied Sciences (2026) https://doi.org/10.3390/app16062864

[61] Chen, X., *et al.*: Eun: Enhanced unlearnable examples generation approach for privacy protection. Computer Vision and Image Understanding (2025) https://doi.org/10.1016/j.cviu.2025.104388

[62] Paik, S., Hwang, C., Seo, J.H.: Toward generating unlearnable examples for open-set face recognition. IEEE Signal Processing Letters (2026) https://doi.org/10.1109/lsp.2026.3707806

[63] Wang, B., *et al.*: Reversible unlearnable examples: Toward the copyright protection in deep learning era. IEEE Transactions on Circuits and Systems for Video Technology (2026) https://doi.org/10.1109/tcsvt.2025.3619199

[64] Meng, R.-H., *et al.*: Semantic deep hiding for robust unlearnable examples. IEEE Transactions on Information Forensics and Security (2024) https://doi.org/10.1109/tifs.2024.3421273

[65] Gong, X., *et al.*: Armor: Shielding unlearnable examples against data augmentation. IEEE Transactions on Pattern Analysis and Machine Intelligence (2026) https://doi.org/10.1109/tpami.2026.3652456

[66] Zhang, C., Tang, Z., Li, K.-L.: Clean-label poisoning attack with perturbation causing dominant features. Information Sciences (2023) https://doi.org/10.1016/j.ins.2023.03.124

[67] Hapuarachchi, T., Xiong, K.: Advancing ensemble learning against unlearnable data. Neurocomputing (2025) https://doi.org/10.1016/j.neucom.2025.130422

[68] Li, J., *et al.*: Wavelet domain steganography for robust unlearnable data. Pattern Recognition (2026) https://doi.org/10.1016/j.patcog.2026.114422

[69] Qin, T., et al.: Apbench: A unified benchmark for availability poisoning attacks

and defenses. Transactions on Machine Learning Research (2024)